





■■■ RAG■■■■■

RAG

■■■■■■■■■■PDF/Word/HTML■■→ ■■■■■■Chunking■■→ ■■■■■■Embedding■■→ ■■■■■■■■■■

■■■■■■■■■■ → ■■■■■Top-K■ → Cross-Encoder■■ → ■■Prompt → LLM■■■■■

■■■■■■■■■Chroma■■■■■■■Weaviate■■■■■■■Pinecone■■■■■■■

PDF

PDF

1. PDF OCR

2.

3. chunk_size=800, overlap=150

4. chunk

□ □ □ □ □ □ □ □ □ □

□ □ □ □ □ □ □ □ □ □ □ □ □ □ □ □

- all-MiniLM-L6-v2 384
- text2vec-large-chinese
- OpenAI text-embedding-3-large 1536 API
- BGE-M3

BGEtext2vec



- [illegible]

[illegible]

Task	RAG	Agent+RAG
1. Text classification	0.85	0.85
2. Sentiment analysis	0.80	0.80
3. Named entity recognition	0.75	0.75
4. Question answering	0.60	0.85
5. Summarization	0.55	0.80
6. Text generation	0.50	0.75
7. Machine translation	0.45	0.70
8. Image classification	0.40	0.65
9. Image captioning	0.35	0.60
10. Video classification	0.30	0.55

RAG